

Informe técnico

Modernización del backend legacy del Banco XYZ

Evaluación Final Transversal

Desarrollo Backend III (PBY2203) · Semana 9

Ignacio Miño Astorga

Analista Programador Computacional · Duoc UC

Repositorio: https://github.com/Ign14/DB3_ExpSumativas

Carpeta del proyecto: EFT_S9_Backend_Avanzado

1. Resumen ejecutivo

El Banco XYZ opera desde hace más de treinta años sobre COBOL y scripts Shell en mainframe. El sistema funciona, y ese es parte del problema: funciona lo suficiente como para que reemplazarlo parezca caro, y lo justo como para que cada cambio cueste meses. Tres informes críticos —transacciones diarias, intereses y estados de cuenta anuales— corren por lotes sobre archivos planos; tres canales distintos —navegador, aplicación móvil y cajero automático— piden lo mismo a un backend monolítico que no distingue entre ellos; y un fallo en cualquier módulo afecta al sistema entero.

Este proyecto entrega el reemplazo. Son **quince módulos Maven** que cubren las tres piezas del problema y se despliegan juntos:

Los **procesos batch** se reescribieron en Spring Batch, con particionamiento, políticas de omisión y reintento, y reejecución automática ante fallos críticos. Procesan las mismas tres mil filas del sistema legacy —con sus errores intencionales— sin detenerse, y dejan registrada cada anomalía con su motivo.

El **patrón Backend for Frontend** da a cada canal su propio backend. La misma cuenta se sirve en 4.914 bytes al navegador, 215 a la aplicación móvil y 39 al cajero, y cada canal tiene credenciales y permisos distintos.

Los **microservicios** parten el dominio en tres servicios independientes, con configuración centralizada, descubrimiento dinámico, OAuth 2.0 con JWT validado en dos capas, tolerancia a fallos con Resilience4j y una arquitectura de eventos sobre Kafka y JMS. Los tres escalan horizontalmente sin cambiar configuración.

El estado del sistema, medido: **168 pruebas automatizadas sin librerías de mocks** y **veintisiete registros de ejecución** repartidos en tres entornos —once sobre los jar, nueve sobre contenedores en el equipo de desarrollo y siete en una **instancia EC2 de AWS**, con el sistema completo y sus dos brokers de mensajería corriendo fuera del equipo de desarrollo—. El ciclo completo del circuit breaker —CLOSED → OPEN → HALF_OPEN → CLOSED— está capturado sobre contenedores reales en los dos últimos.

Este informe describe qué se construyó, por qué se tomó cada decisión, qué problemas aparecieron durante el desarrollo y qué falta. La última sección es deliberadamente específica: hay cinco cosas que este sistema necesita antes de ver tráfico real, y están nombradas con su motivo.

2. Requerimientos clave del negocio

Antes de la arquitectura están los requerimientos, porque son los que la justifican. Del caso del Banco XYZ se desprenden tres, y cada decisión técnica de este informe responde a alguno.

2.1 Continuidad operacional durante y después de la migración

El banco no puede apagar el sistema legacy y encender el nuevo. Los informes diarios tienen que seguir saliendo, y los resultados del sistema nuevo tienen que ser **equivalentes** a los del

antiguo, no parecidos.

Qué implica, concretamente: los procesos batch deben leer los mismos archivos, aplicar las mismas reglas y producir las mismas salidas; los datos sucios —que el sistema legacy toleraba a su manera— no pueden detener un proceso completo; y un fallo transitorio de infraestructura no puede dejar un informe sin generar sin que nadie se entere.

Cómo lo responde la arquitectura: tres Jobs independientes con particionamiento, política de omisión por registro con el motivo registrado, reintento de chunk para el fallo transitorio, reejecución automática del Job para el fallo crítico, y un código de salida distinto de cero cuando algo quedó sin procesar.

2.2 Independencia entre canales y velocidad de desarrollo

Hoy los tres frontends dependen del mismo backend, lo que significa que ninguno puede evolucionar sin coordinarse con los otros dos, y que todos reciben los mismos datos aunque muestren cosas distintas. El banco necesita que el equipo de la aplicación móvil pueda cambiar su pantalla sin esperar al equipo del cajero.

Qué implica: cada canal debe tener un backend propio, desplegable por separado, con una API ajustada a lo que ese canal muestra; y la seguridad debe distinguir entre canales, porque no tienen el mismo riesgo.

Cómo lo responde la arquitectura: tres BFF independientes, cada uno con su propio cliente OAuth 2.0 y sus propios scopes. El canal móvil no tiene ningún permiso de escritura; el cajero no puede leer datos personales ni historiales.

2.3 Resiliencia y escalabilidad bajo carga variable

Un banco tiene carga desigual: fin de mes, día de pago, horario comercial. Y tiene dependencias que fallan. El sistema debe seguir sirviendo lo que pueda cuando una parte se cae, y debe poder crecer en la parte que lo necesite sin crecer entera.

Qué implica: ningún componente puede ser un punto único de falla por diseño; una dependencia caída debe degradar la respuesta, no tumbarla; y agregar capacidad a un servicio no debe requerir cambiar configuración de los demás.

Cómo lo responde la arquitectura: circuit breaker con respuesta degradada sobre las consultas, rechazo honesto sobre las operaciones que mueven dinero, mensajería asíncrona que desacopla productores de consumidores, y balanceo de carga sobre un registro de servicios que permite replicar cualquier microservicio con una bandera.

3. Los cinco procesos de la migración


La modernización se descompone en cinco procesos, y conviene verlos juntos antes del detalle porque cada uno habilita al siguiente.

#	Proceso	Qué resuelve	Dónde está
1	Migración de los procesos batch a Spring Batch	Los tres informes críticos dejan de depender de COBOL	batch-migracion
2	División del monolito en microservicios	Cada dominio se despliega y escala por separado	cuentas-service , pagos-service , clientes-service
3	Patrón Backend for Frontend	Cada canal recibe lo que necesita, ni más ni menos	bff-web , bff-movil , bff-cajero
4	Seguridad distribuida con Spring Cloud Security	La autorización deja de ser central y se aplica en cada salto	auth-server , api-gateway , los tres microservicios
5	Mensajería asíncrona con Kafka (y JMS)	Los servicios dejan de llamarse entre sí para todo	Kafka, Artemis, los tres microservicios

El orden no es arbitrario. Sin el proceso 1 no hay datos limpios con los que alimentar nada. Sin el 2, no hay a quién ponerle un BFF delante. Sin el 4, el 2 abre una superficie de ataque en vez de resolver un problema. Y el 5 es el que convierte un conjunto de servicios que se llaman entre sí en un sistema que tolera que una parte se caiga.

4. Propuesta de arquitectura

4.1 Vista general



El sistema tiene cuatro capas y una sola puerta de entrada.


Los **canales** no hablan con el dominio: hablan con su BFF. El BFF agrega, recorta y traduce, y cruza el `api-gateway` con un token propio.

El **gateway** es la única puerta. Valida la firma y el issuer del JWT antes de enrutar, y resuelve el destino por nombre de servicio en Eureka, no por host y puerto. Esa segunda parte es lo que hace que replicar un microservicio sea gratis.

Los **microservicios de dominio** son dueños de sus datos y de sus reglas. Se hablan entre sí lo mínimo, y cuando lo hacen es con un token propio y con políticas de resiliencia encima.


La **mensajería** desacopla lo que no necesita respuesta inmediata, y usa dos tecnologías distintas a propósito (sección 5.5).

4.2 Componentes y responsabilidades



Módulo	Puerto	Responsabilidad
common-dominio	—	DTOs de las APIs y los tres eventos. Es el único contrato compartido, y lo usan tanto los microservicios como los BFF
batch-migracion	—	Los tres Jobs de Spring Batch
config-server	8888	Sirve la configuración de todo el ecosistema, con autenticación básica
discovery-server	8761	Eureka, con autenticación básica
auth-server	9000	Spring Authorization Server: emite JWT por client_credentials
api-gateway	8080	Valida el token y enruta con lb://
cuentas-service	8081	Saldo, titular, retiros y las primitivas de liquidación
pagos-service	8082	Depósitos, transferencias, historial y el reporte diario
clientes-service	8083	Datos personales y la proyección de actividad desde Kafka
broker-artemis	61616	Broker JMS de la cola de retiros
broker-kafka	9092	Broker Kafka para la ejecución local sin Docker
bff-common	—	Cientes HTTP y gestor de tokens compartidos por los tres canales
bff-web	8091	Canal web: consola administrativa
bff-movil	8092	Canal móvil: payload mínimo
bff-cajero	8093	Canal cajero: saldo y retiro

4.3 Casos de uso



Hay cuatro actores y la distinción importa, porque es la que determina los permisos. El **titular** consulta y retira; el **operador del banco** hace todo lo anterior más mover dinero y editar datos personales; el **cajero automático** es un actor por sí mismo, con el conjunto de operaciones más pequeño; y el **proceso programado** ejecuta los tres jobs batch sin intervención humana.

5. Decisiones técnicas y su justificación

Esta sección es el núcleo del informe. Cada decisión se presenta con la alternativa que se descartó, porque una decisión sin alternativa descartada no es una decisión.

5.1 Tres niveles de respuesta al fallo en el batch

El problema. El dataset legacy trae mil filas por archivo con errores sembrados: montos negativos y cero, fechas en cuatro formatos distintos, campos vacíos, edades de 100 y de 5, tipos de cuenta que dicen `-1`, cuentas duplicadas con valores que no coinciden. Un proceso que se detiene ante la primera fila mala no sirve; uno que las acepta todas corrompe los datos.

La decisión. Tres niveles distintos, porque son tres problemas distintos:

Nivel	Qué es	Respuesta	Por qué
Fila inválida	Un monto negativo, una fecha imposible	Se omite, se registra la anomalía con su motivo, el proceso sigue	Es un problema del dato, no del sistema. Detenerse sería perder las 999 filas buenas
Fallo transitorio	La base rechaza una conexión por un instante	Reintento del chunk, hasta el límite configurado	Volver a intentar lo resuelve
Fallo crítico	La base se cae a mitad del Job	Reejecución automática del Job, hasta dos veces	Es lo que haría un operador, y automatizarlo ahorra la espera

La alternativa descartada. Tratar todo como fallo transitorio. Habría significado reintentar mil veces una fila que nunca va a validar, y un límite de omisiones que nunca se alcanza porque las omisiones se disfrazan de reintentos.

El detalle que casi se pasa por alto. El `ResolverStyle.STRICT` del parser de fechas. En el modo por defecto, `DateTimeFormatter` acepta `31/02/2024` y lo convierte silenciosamente en el 29 de febrero. Un parser así "funciona" y corrompe datos: un framework que arregla la basura por su cuenta es peor que uno que falla.

Vale la pena decir cómo terminó estando ahí, porque la historia es más instructiva que la decisión. El sistema tenía **dos copias** de este parser: la de `pagos-service`, que era estricta y tenía un test con `31/02/2024`, y la de `batch-migracion`, que no era ninguna de las dos cosas. Los documentos describían la versión estricta hablando del batch. Ninguna prueba comparaba las dos copias, así que nada fallaba. Lo detectó una auditoría del proyecto terminado, y la sección 7.6 cuenta el resto.

5.2 Un límite por canal además del límite del dominio

El problema. ¿Dónde vive el límite máximo de un retiro?

La decisión. En los dos lados, con significados distintos. El cajero rechaza sobre 500.000 antes de llamar a nadie, porque un cajero dispensa billetes y tiene restricciones físicas que la cuenta no conoce. `cuentas-service` tiene su propio límite configurable, que es la regla del negocio y se puede cambiar en el Config Server sin recompilar. Y la suficiencia de fondos es una invariante del dominio que vive dentro de la operación atómica del repositorio.

Por qué no es duplicación. Validar en el canal ahorra una llamada remota para algo que se resuelve mirando el cuerpo de la petición. Y los tres límites responden preguntas distintas: cuánto puede dispensar esta máquina, cuánto permite el banco por operación, y cuánto hay en la cuenta.

5.3 Invariantes dentro de la operación atómica

El problema. El registro de una cuenta es inmutable y cada débito lo reemplaza por otra instancia. Dos retiros simultáneos sobre la misma cuenta pueden partir del mismo saldo y perderse uno.

La decisión. Leer el saldo, validar los fondos y escribir el nuevo saldo son una sola operación atómica sobre la clave, usando `ConcurrentHashMap.compute`. Y las invariantes —monto positivo, saldo no negativo— se comprueban **dentro** de ese bloque, no en la capa de servicio.

Por qué ahí y no en el servicio. Parece inofensivo mientras haya un solo llamador, pero un monto negativo en un `subtract` aumenta el saldo. El segundo llamador que aparezca podría crear dinero de la nada. Una invariante que vive fuera de la operación atómica no es una invariante.

Hay tests de concurrencia con veinte hilos sobre los tres repositorios que cubren este caso.

5.4 Seguridad: dos barreras y seis scopes

El problema. ¿Dónde se valida el token, y con qué granularidad?

La decisión. Dos barreras que no se reemplazan entre sí. El **gateway** valida firma e issuer antes de enrutar, de modo que un token inválido no consume recursos de ningún microservicio. Cada **microservicio** vuelve a validar y además comprueba el scope concreto que exige cada endpoint.

La alternativa descartada. Validar sólo en el gateway. Habría significado que cualquier proceso dentro de la red interna pudiera llamar a los servicios sin token: el gateway sería una puerta con un muro de un metro al lado.

Los seis scopes y su reparto:

Cliente	Scopes	Justificación
banco-web-client	los seis	Consola administrativa: el único que mueve dinero por transferencia y edita datos personales
banco-movil-client	cuentas.read , movimientos.read , clientes.read	Un teléfono que se pierde, se presta o se roba no debe poder mover dinero con el token que lleva dentro
cajero-client	cuentas.read , cuentas.write	Un cajero comprometido no debe convertirse en una fuente de información personal
pagos-service	cuentas.read , cuentas.liquidar	Necesita mover las puntas de una transferencia, no pedir retiros

El scope que apareció durante el desarrollo. Al agregar las transferencias, `pagos-service` necesitaba mover saldo. Lo rápido era darle `cuentas.write`, que ya existía. Pero `cuentas.write` autoriza a pedir un retiro, que es una operación de canal con su límite y su evento, y este servicio no tiene por qué poder pedirla. De ahí salió `cuentas.liquidar`, un scope que no tiene ningún canal: el mínimo privilegio no se reparte usando el permiso que ya existe porque alcanza, se crea el permiso que describe lo que esa parte hace.

El efecto se puede comprobar en la evidencia: el token del cajero, con firma perfectamente válida, recibe 200 en `/api/cuentas/101` y **403** en `/api/movimientos/101` y `/api/clientes/101`.

5.5 Dos brokers, no uno

El problema. El caso pide Kafka. El sistema ya tenía JMS funcionando. Lo cómodo era migrar todo a Kafka.

La decisión. Quedarse con los dos, porque llevan mensajes de naturaleza distinta:

	Cola JMS	Tópico Kafka
Qué lleva	Una instrucción con destinatario	Un hecho sin destinatario
Ejemplo	"Anota este retiro en el historial"	"Esta transacción ocurrió"
Cuántas veces se procesa	Exactamente una	Una vez por cada consumidor interesado
Si el consumidor está caído	El mensaje espera	El evento queda en el tópico con su retención
Consumidores futuros	Le robarían mensajes al primero	Se suman sin que el productor cambie

Por qué no uno solo. Con una sola cola, el segundo consumidor que apareciera le robaría mensajes al primero. Con un solo tópico, habría que inventar la garantía de procesamiento único que la cola ya da.

Tres detalles de la configuración de Kafka que importan:

La **clave del mensaje es el número de cuenta**. Kafka ordena dentro de una partición y una misma clave cae siempre en la misma partición, así que un consumidor nunca ve el segundo retiro de una cuenta antes que el primero, aunque el tópico tenga tres particiones.

El **consumidor declara a qué tipo deserializar**, en vez de leerlo del encabezado que escribe el productor. Ese encabezado acopla los servicios por el nombre de sus paquetes y,

peor, le pediría a este proceso instanciar una clase cualquiera del classpath si alguien lo manipulara.

Cada deserializador va envuelto en `ErrorHandlingDeserializer`. Sin eso, un mensaje con JSON inválido hace fallar la deserialización antes de que el listener exista, el contenedor reintenta el mismo offset para siempre, y el consumo del tópico se detiene. Un solo mensaje mal formado basta para dejar de procesar todo lo que venga detrás.

5.6 Tolerancia a fallos: dónde hay fallback y dónde no

El problema. `pagos-service` llama a `cuentas-service` para dos cosas muy distintas: leer datos de una cuenta y mover su saldo. ¿La misma política para las dos?

La decisión. No. Y es la decisión más importante del sistema en materia de resiliencia.

La **consulta de la ficha** lleva `Retry`, `CircuitBreaker`, `TimeLimiter` y **fallback**. Si la dependencia no responde, se entrega el historial sin los datos de la cuenta, marcado como `DEGRADADO`. Para quien consulta movimientos, el nombre del titular es un adorno; el historial es el dato que vino a buscar.

Las **primitivas de liquidación** llevan `Retry` y `CircuitBreaker` pero **deliberadamente ningún fallback**. Un cargo que no se pudo aplicar no tiene versión degradada: o el dinero se movió o no se movió. Devolver "aprobado en modo degradado" sería decirle al cliente que su transferencia salió cuando el saldo no cambió. La excepción tiene que subir para que quien orquesta la operación la compense o la rechace.

El orden de las anotaciones. `Resilience4j` envuelve de afuera hacia adentro como `Retry`, `CircuitBreaker`, `TimeLimiter`, así que el fallback va declarado en `@Retry`, la capa más externa. Si estuviera en `@CircuitBreaker`, el primer fallo se convertiría en un valor de retorno válido, `Retry` vería éxito y no reintentaría nunca.


El presupuesto de tiempo. Los números tienen que ser coherentes entre capas o se estorban:

```
por intento: 1 s de conexión + 1 s de lectura = 2 s, acotados por el TimeLimiter en 2 s
peor caso:   2 s + 0,2 s de espera + 2 s = 4,2 s hasta la respuesta degradada
```

Si el `TimeLimiter` fuera más corto que el peor caso del HTTP, cortaría la espera del cliente pero dejaría la petición viva ocupando un hilo. Si fuera más largo, el que acotaría de verdad sería el cliente HTTP y el `TimeLimiter` no serviría de nada.

Qué cuenta como fallo. Sólo `ServicioNoDisponibleException` y `TimeoutException`. Un 404 significa que el servicio respondió bien y la cuenta no existe: si contara como fallo, consultar cuentas inexistentes abriría el circuito de las válidas. Un 401 o un 403 son un problema de configuración permanente, y abrir el circuito sólo lo disfrazaría de caída pasajera.

5.7 Consistencia de una transferencia distribuida



El problema. Una transferencia son dos llamadas remotas y no existe una transacción que abarque a las dos. Es el primer caso del sistema donde no hay respuesta correcta y hay que elegir qué equivocación es más barata.

La decisión, en tres partes:

Se carga antes de abonar. Si falla la primera punta, no hay nada que deshacer. Al revés — abonar y después cargar— un fallo en la segunda dejaría dinero creado, que es el error más caro de los dos.

Se compensa la punta aplicada. Si el abono al destino falla, se devuelve el monto a la cuenta de origen y queda un movimiento de reverso en el historial. Es una compensación de negocio, no un rollback: las tres operaciones dejan rastro.

Si la compensación también falla, se grita. Ahí hay un descalce contable real. Se registra con severidad alta, con todos los datos necesarios para reponerlo a mano, y se publica en el tópico de alertas. No se reintenta en un bucle ni se traga el error.

Lo que falta y por qué. Una clave de idempotencia por operación permitiría reintentar sin duplicar, y un registro durable de operaciones en curso permitiría retomar la compensación si el proceso se cae en el peor momento. Con estado en memoria no se puede sostener ninguna de las dos. Está dicho en el código, en el `readme.md` y en la sección 9 de este informe.

Los doce tests de `PagoServiceTest` cubren estos caminos; cuatro de ellos son específicamente sobre compensación.

5.8 Balanceo del lado del cliente, no por el gateway

El problema. `pagos-service` llama a `cuentas-service`. Si hay dos instancias de `cuentas-service`, ¿cómo se reparte ese tráfico?

La decisión. Un `RestClient` marcado con `@LoadBalanced`, cuya URL base es el nombre del servicio en Eureka (`http://cuentas-service`) y no un host fijo. Spring Cloud resuelve una instancia distinta en cada petición.

La alternativa descartada. Mandar el tráfico interno por el `api-gateway`, que también balancea. Habría funcionado, pero agrega un salto de red a cada llamada entre servicios y convierte la puerta de entrada en un cuello de botella por el que tendría que fluir también todo el tráfico interno.

El resultado medido: con dos instancias levantadas, treinta peticiones por el gateway se repartieron 15 y 15, y veinte llamadas entre servicios se repartieron 10 y 10, contadas en los logs de acceso de cada instancia.

6. Resultados y comparación con el sistema legacy

6.1 Comparación estructural

Dimensión	Sistema legacy	Sistema nuevo
Plataforma	COBOL y Shell sobre mainframe	Java 21, Spring Boot 3.3, contenedores
Procesos batch	Secuenciales, un solo hilo	Particionados en cuatro, en paralelo, con grilla configurable
Ante un dato sucio	Comportamiento del sistema antiguo, no auditable	Se omite, se registra la anomalía con su motivo y el proceso sigue
Ante un fallo crítico	Intervención manual	Reejecución automática y código de salida que un cron puede detectar
Canales	Un backend para los tres	Un backend por canal, desplegable por separado
Payload para la misma cuenta	El mismo para todos	4.914 / 215 / 39 bytes según el canal
Seguridad	Centralizada	OAuth 2.0 con JWT, seis scopes, validación en dos capas
Ante la caída de un módulo	Afecta al sistema completo	El circuito se abre, la respuesta se degrada y el evento espera en la cola
Escalar	Toda la plataforma	Un servicio, con una bandera
Despliegue	Proceso del mainframe	<code>docker compose up -d</code> , once imágenes construidas desde el repositorio
Configuración	En cada programa	Centralizada, versionada y autenticada
Pruebas automatizadas	No documentadas	168, sin librerías de mocks

6.2 Resultados medidos

Procesamiento batch. Los tres jobs procesan 1.000 filas cada uno, repartidas en cuatro particiones que corren en paralelo, en menos de dos segundos por job:

Job	Escritos	Omitidos
Reporte de transacciones diarias	392	608
Cálculo de intereses	422	578
Estados de cuenta anuales	604	396

Las omisiones no son fallos: son exactamente los errores que el dataset trae sembrados, cada uno registrado con su motivo. El archivo de movimientos diarios es el más sucio de los tres, con un 60 % de filas inválidas.

Esa cifra obligó a calibrar el límite de omisiones y, al hacerlo, apareció algo que no es evidente: Spring Batch aplica el límite **por ejecución de Step, no por archivo**, así que con particionamiento cada partición lleva su propia cuenta. Con el límite en 200, este archivo fallaba con una partición y pasaba con cuatro. Quedó en 700 para que el resultado sea el

mismo con cualquier grado de paralelismo, que es lo mínimo que se le pide a un proceso por lotes.

Diferenciación por canal. Para la cuenta 101, el canal web devuelve 4.914 caracteres con el historial completo, el perfil del titular y los totales; el móvil, 215 con el saldo y tres movimientos de tres campos cada uno; el cajero, 39 con el número de cuenta y el saldo. Dos órdenes de magnitud entre los extremos.

Control de acceso. Siete combinaciones de canal y recurso probadas: el cajero recibe 403 en movimientos y en clientes, el canal móvil recibe 403 al intentar escribir, y ningún canal puede liquidar saldo directamente.

Tolerancia a fallos. Con `cuentas-service` detenido, el circuito pasó a `OPEN` tras la segunda petición y las siguientes respondieron de inmediato en modo degradado, sirviendo el historial completo. Al volver a levantar el servicio, el circuito recorrió `CLOSED → OPEN → HALF_OPEN → CLOSED` y volvió a cerrarse solo, sin intervención: diez segundos en abierto, una prueba en medio abierto que pasó, y el tráfico restablecido.

Sobre contenedores, donde el servicio tarda más en estar listo, es normal ver una variante: `HALF_OPEN → OPEN → HALF_OPEN → CLOSED`, porque la prueba en medio abierto llega mientras el contenedor todavía descarga su configuración y se registra en Eureka. Es el mismo mecanismo y, si aparece, es mejor evidencia que un ciclo limpio, porque es lo que pasaría en un incidente real.

Mensajería. Un retiro bajó el saldo en `cuentas-service` y apareció en el historial de `pagos-service` sin que un servicio llamara al otro. Con el consumidor detenido, el retiro se aprobó igual y el evento esperó en la cola hasta que el consumidor volvió. En Kafka, cuatro transacciones y una alerta llegaron a `clientes-service`, que actualizó la actividad de dos titulares distintos a partir de una sola transferencia.

Escalabilidad. Dos instancias de `cuentas-service` registradas en Eureka, treinta peticiones repartidas 15 y 15 por el gateway y veinte llamadas entre servicios repartidas 10 y 10, sin cambiar configuración de ningún componente.

6.3 Lo que el sistema nuevo todavía no mejora

Para que la comparación sea honesta: el sistema legacy **persiste** sus datos y este no. Los tres microservicios cargan los CSV al arrancar y mantienen el estado en memoria, así que un reinicio pierde los movimientos de la sesión. En esa dimensión concreta, el sistema antiguo es mejor hoy. Es el primer punto de la sección 9.

7. Desafíos enfrentados y soluciones

7.1 La infraestructura estaba abierta

El problema. Revisando el proyecto ya terminado apareció que los componentes de infraestructura no pedían credenciales. El más grave era el **Config Server**: devuelve la configuración completa de todos los microservicios, y ahí dentro viaja el secreto del cliente OAuth 2.0 de `pagos-service`. Un `GET` anónimo entregaba una credencial con la que cualquiera

podía pedirle al `auth-server` un JWT perfectamente válido. Todo el esquema de scopes quedaba neutralizado por la puerta de al lado.

Eureka era el segundo: el registro decide a dónde va el tráfico, así que cualquiera podía dar de baja un servicio o registrar uno propio con el nombre de `cuentas-service` y recibir las peticiones del gateway. **Artemis** era el tercero: Spring Boot configura el broker embebido con `setSecurityEnabled(false)`, y con un acceptor TCP abierto eso deja un camino de escritura al dominio que no pasa por ningún token.

La solución. Autenticación básica en el Config Server y en Eureka; y en Artemis, un único usuario con un rol acotado y la seguridad encendida a mano con un `BeanPostProcessor`, porque Spring Boot no ofrece un punto de extensión para ponerla.

Lo que dejó. Encender la seguridad de Artemis rompió el indicador de salud de Spring Boot, que usa una factoría de conexiones sin credenciales y reportaba `DOWN` con el broker sano. Se reemplazó por un indicador propio que le pregunta al servidor embebido.

7.2 El servicio que arrancaba sano y respondía otra cosa

El problema. Los tres BFF quedaron `UP` según sus logs, pero su endpoint de salud devolvía 302. El healthcheck los daba por caídos y no había ningún error en ningún log.

La causa. Los BFF dependen de `spring-boot-starter-oauth2-client` para poder pedir su token, y el solo hecho de tener esa dependencia en el classpath hace que Spring Security proteja todas las rutas con un formulario de login. El servicio estaba sano y respondiendo: respondiendo una redirección a una página de login.

La solución. Una cadena de filtros explícita en el módulo común, con la decisión documentada: los BFF no autentican al usuario final en esta entrega porque el flujo del sistema es `client_credentials` —se autentican aplicaciones, no personas—, y lo que cada BFF protege es el backend, no a sí mismo.

Lo que enseñó. Un comportamiento por defecto que nadie eligió es más difícil de encontrar que un error, porque no deja rastro. El healthcheck que mira el código de respuesta y no sólo si el puerto contesta fue lo que lo delató.

7.3 La transferencia que puede quedar a medias

El problema. Descrito en la sección 5.7. No tiene solución completa sin persistencia.

La solución parcial, y por qué se asumió. Cargar antes de abonar, compensar si falla, y gritar si la compensación falla. Las tres partes tienen tests. Lo que no se hizo fue fingir que el problema está resuelto: la clave de idempotencia faltante está escrita en el código, en el `readme.md` y en la sección 9.

7.4 Integrar no era juntar

El problema. La primera idea fue que integrar las tres experiencias era ponerlas en una carpeta y escribir un documento que las explicara.

Lo que apareció al unirlas. Los BFF de la semana 5 hablaban con dos servicios "core" propios que, en el sistema integrado, ya no tenían razón de existir: los microservicios cubren

el mismo dominio, mejor. Los BFF pasaron a consumir el gateway y tuvieron que volverse clientes OAuth 2.0, algo que antes no necesitaban.

Y el retiro por cajero cambió de forma: antes el BFF orquestaba dos llamadas y cargaba con el problema de que la segunda fallara después de que el dinero ya había salido. Con la cola, esa orquestación dejó de ser suya. **Es el único caso del proyecto en que agregar una capacidad de arquitectura eliminó código de otra capa en vez de agregarlo.**

7.5 El contrato duplicado que mostraba cero

El problema. El canal web devolvía, para una cuenta con cuarenta movimientos, un resumen que decía `"cantidadMovimientos": 0` y `"ultimoMovimientoFecha": null`. Los totales de depósitos y egresos salían correctos. Nada fallaba, ningún log decía nada, y los otros dos canales estaban bien.

La causa. Al integrar las tres experiencias, el módulo común de los BFF se quedó con su propia copia de los DTOs en vez de usar el contrato del dominio. Las dos copias eran casi iguales, y ese "casi" era todo: el microservicio publica `totalMovimientos` y `ultimaFecha`, la copia del BFF los llamaba `cantidadMovimientos` y `ultimoMovimientoFecha`. Jackson no tiene por qué quejarse de un campo que no reconoce ni de uno que no viene: deserializa lo que coincide y deja el resto en su valor por defecto. Cero y nulo.

La solución. Eliminar la duplicación, no renombrar los campos. El módulo de los BFF pasó a depender de `common-dominio` y los nueve records duplicados desaparecieron. El único que se conservó es el comprobante que el cajero le entrega al titular, que sí es distinto del que devuelve el dominio, y se renombró a `ComprobanteRetiro` para que el código diga que son dos cosas distintas.

Lo que enseñó. Dos copias de un contrato no son redundancia: son dos contratos que se parecen hasta que dejan de parecerse, y el día que dejan de parecerse nadie se entera, porque la serialización no falla, rellena. Es el argumento más concreto que encontré a favor de un módulo de contratos compartido, y lo encontré teniéndolo ya escrito en el informe y sin cumplirlo.

7.6 Lo que encontré auditar el proyecto terminado

Las dos secciones anteriores y la 7.1 tienen algo en común que conviene decir explícito: **ninguno de esos tres defectos apareció probando el sistema**. La infraestructura sin autenticación, el parser que decía ser estricto y no lo era, y el contrato duplicado que mostraba cero, los tres pasaron por delante de 136 pruebas en verde y de una evidencia de ejecución completa.

Aparecieron al revisar el proyecto ya terminado preguntando qué podía estar mal, que es una actividad distinta de probar que lo construido funciona. Las pruebas responden "¿hace lo que le pedí?"; la revisión responde "¿qué le pedí que no debería haberle pedido, y qué no le pedí?".

De esa revisión salieron además las pruebas que faltaban, y la suite pasó de 136 a 168: las reglas de autorización por endpoint, que eran la afirmación de seguridad central del proyecto y no tenían ninguna; el caso de las fechas imposibles en el parser del batch, que es el que habría detectado el defecto años antes; la concurrencia del repositorio de movimientos, que

dos documentos daban por cubierta y no lo estaba; y la agregación del canal web, que era el BFF más complejo y el único sin pruebas.

7.7 Un script que se corrompió a sí mismo

El problema. Durante la generación de la evidencia, el script de ejecución falló a mitad de camino con un error de sintaxis en una línea que estaba perfectamente escrita.

La causa. Bash lee los scripts de forma incremental, no completa. Editar el archivo mientras corre desplaza los desplazamientos de bytes y el intérprete retoma la lectura en una posición desfasada, partiendo una palabra por la mitad.

La solución. Esperar a que termine antes de editarlo. Vale anotarlo porque es un modo de falla que no se parece a un error del programa y hace perder tiempo buscando en el lugar equivocado.

8. Pruebas y evidencia

8.1 Estrategia de pruebas

168 pruebas automatizadas, sin librerías de mocks. Los dobles de prueba están escritos a mano, y la razón es concreta: las librerías de mocks instrumentan bytecode y se rompen al cambiar de versión del JDK. Este proyecto se desarrolló con JDK 24 y compila con `release 21`, y tiene que correr igual donde se revise. La evidencia de `evidencia/local/` se generó con JDK 21 sobre Linux —así lo declara la cabecera de `01_compilacion_y_pruebas.log`—, lo que es la comprobación de que el bytecode es el mismo en los dos. Una subclase de tres líneas no tiene ese problema.

Módulo	Pruebas	Qué cubren
<code>batch-migracion</code>	15	Los tres procesadores, el parser de fechas legacy —incluidas las fechas imposibles— y las reglas de validación
<code>auth-server</code>	10	El mínimo privilegio de cada canal, con igualdad exacta de conjuntos
<code>cuentas-service</code>	33	Retiros, liquidación, eventos publicados, concurrencia de veinte hilos y las reglas de autorización por endpoint
<code>pagos-service</code>	66	Resiliencia cableada, orquestación de pagos, compensación, consumo JMS, concurrencia y reglas de autorización
<code>clientes-service</code>	22	Carga del padrón, proyección de eventos, concurrencia y reglas de autorización
<code>bff-web</code>	8	Agregación de cuatro llamadas y la degradación parcial cuando falta el perfil
<code>bff-movil</code> , <code>bff-cajero</code>	14	Recorte por canal y límites del canal

Tres elecciones que vale explicar.

Los tests del `auth-server` usan **igualdad exacta** de conjuntos de scopes y no "contiene": un test que comprueba que el cajero contiene `cuentas.write` sigue pasando el día en que alguien

le agregue `clientes.read`, y ese es precisamente el cambio que debería hacer ruido.

Los tests de concurrencia usan **veinte hilos con una barrera de partida**, no llamadas secuenciales. Sin la barrera, los hilos se ejecutan de a uno y el test pasa aunque el código no sea atómico.


Y los tres `ReglasDeAutorizacionTest` prueban la **cadena de filtros**, no los controladores: levantan un contexto mínimo con la configuración de seguridad real y un controlador de sonda que declara las mismas rutas sin lógica, de modo que un 403 sólo puede venir de la autorización. Cubren el hueco que esta misma suite tenía hasta hace poco: el `auth-server` verificaba qué scopes tiene cada cliente, pero nada verificaba qué scope exige cada endpoint, así que la distinción entre `cuentas.write` y `cuentas.liquidar` —la decisión de seguridad más fina del sistema— podía romperse sin que fallara una sola prueba. Cada uno termina comprobando que una ruta no declarada queda denegada, que es lo que hace que un endpoint nuevo nazca cerrado.

8.2 Evidencia de ejecución

Tres conjuntos, que demuestran cosas distintas y por eso no se mezclan. `evidencia/local/` contiene la ejecución sobre los jar, reproducible en cualquier máquina con un JDK y sin depender de Docker. `evidencia/docker/` contiene la ejecución sobre contenedores en el equipo de desarrollo, que demuestra que las once imágenes se construyen y que la orquestación declarada levanta el ecosistema. Y `evidencia/nube/` contiene la ejecución del sistema completo —incluidos los dos brokers de mensajería— **dentro de una instancia EC2 de AWS**, que es lo que demuestra que esto funciona fuera del equipo de desarrollo; sus registros empiezan con los metadatos de la instancia leídos del servicio de metadatos de AWS, porque un `docker compose ps` es idéntico en cualquier máquina y sin esa cabecera no habría forma de distinguir una ejecución de la otra.

El índice de los tres conjuntos está en `evidencia/LEEME.md`. Los once registros de `evidencia/local/`:

Registro	Qué demuestra
<code>01_compilacion_y_pruebas</code>	Los quince módulos y las 168 pruebas
<code>02_batch_migracion</code>	Los tres jobs, el escalado por particiones y la política de finalización
<code>03_configuracion_y_discovery</code>	Config Server y Eureka autenticados, servicios registrados
<code>04_oauth2_y_control_de_acceso</code>	Token, claims, clave pública y los rechazos por canal y por scope
<code>05_apis_por_el_gateway</code>	Los tres microservicios respondiendo por el gateway
<code>06_mensajeria_jms</code>	El retiro que cruza dos servicios por la cola, y la cola reteniendo el evento
<code>07_mensajeria_kafka</code>	Los dos tópicos con productores y consumidores reales
<code>08_tolerancia_a_fallos</code>	El ciclo completo del circuit breaker con respuesta degradada
<code>09_bff_por_canal</code>	Los tres canales con payloads distintos para la misma cuenta
<code>10_escalabilidad_horizantal</code>	Dos instancias y el reparto de peticiones entre ellas
<code>11_estado_final</code>	Salud de los doce componentes y de la réplica levantada al escalar, más el registro final de Eureka



9. Propuestas de mejora y próximos pasos

En orden de prioridad. Las cinco están nombradas en el código, donde corresponde, con el motivo de por qué no se resolvieron.

9.1 Persistencia en base de datos

Qué falta. Los tres microservicios cargan los CSV al arrancar y mantienen el estado en memoria.

Por qué es lo primero. Dos instancias de `cuentas-service` tienen cada una su copia del saldo y divergen en cuanto alguien retira. El escalado horizontal que este sistema demuestra es real en el reparto de tráfico, pero sólo es correcto mientras los servicios no tengan estado propio que divergir. Es la diferencia entre una demostración que funciona y un sistema que es correcto.

Qué implica. RDS PostgreSQL —el módulo batch ya trae el perfil `postgres`— y reemplazar los repositorios en memoria por repositorios JPA. La arquitectura distribuida no cambia.

9.2 La clave de firma del `auth-server` fuera del proceso

Qué falta. La clave RSA se genera al arrancar.

Por qué importa. Cada reinicio invalida los tokens vigentes, y dos instancias del `auth-server` firman con claves distintas, de modo que un token emitido por una no valida en la otra. Mientras siga así, ese servicio corre con una sola instancia y es el único punto único de falla del sistema por diseño.

Qué implica. La clave en AWS Secrets Manager o KMS, compartida entre instancias, con rotación solapada entre claves.

9.3 Clave de idempotencia por operación de pago

Qué falta. Una operación no se puede reintentar sin riesgo de duplicarla.

Por qué importa. Es lo que cierra el problema de la sección 5.7. Hoy el abono de una transferencia no se reintenta —reintentar un abono que quizá sí se aplicó regala dinero—, lo que significa que un fallo de red momentáneo en ese punto dispara una compensación innecesaria.

Qué implica. Que `cuentas-service` recuerde las claves de operación ya aplicadas, lo que a su vez requiere 9.1.

9.4 TLS y autenticación del usuario final

Qué falta. El tráfico interno va en claro, y nada verifica a la persona detrás de un canal: los canales se autentican a sí mismos, no a quien los usa.

Qué implica. Terminación TLS en el balanceador —descrita en `despliegue.md`— y una capa de autenticación de usuario por delante de cada BFF: sesión del navegador, token de la aplicación móvil, certificado del cajero.

9.5 Trazabilidad distribuida

Qué falta. Hay endpoints de Actuator y logs por servicio, pero seguir un retiro a través del gateway, dos microservicios, una cola y un tópico requiere leer cinco logs y cruzarlos a mano.

Qué implica. Micrometer Tracing con OpenTelemetry, y un identificador de correlación que viaje también en los mensajes de la cola y en los eventos del tópico, que es la parte que la instrumentación automática no cubre.


9.6 Mejoras de menor prioridad

Más particiones en los tópicos. `clientes-service` consume de tópicos con tres particiones, así que más de tres instancias no aumentan el consumo: Kafka asigna como máximo una partición por consumidor dentro de un grupo. Si hiciera falta escalar más allá de tres, primero hay que aumentar las particiones.

Una cola de mensajes fallidos. Hoy un evento que no se puede procesar se registra y se descarta. Una *dead letter queue* permitiría reprocesarlo después.

Fecha de actualización en el dataset. El archivo de intereses repite cuentas con valores distintos y no trae fecha para desempatar; se conserva la última fila válida. Con datos reales, ese criterio debería reemplazarse por una fecha.

10. Despliegue



El detalle completo —comandos, definiciones de tarea, autoescalado, costos estimados y verificación posterior— está en [despliegue.md](#). Lo esencial:

Las imágenes van a **ECR** y se despliegan como servicios de **ECS Fargate**, en subredes privadas de dos zonas de disponibilidad. Sólo el gateway y los tres BFF se publican tras un **Application Load Balancer** con HTTPS; los tres microservicios de dominio no tienen grupo de destino y sólo son alcanzables desde dentro, igual que en `docker-compose.yml` no publican puertos al host.

Kafka pasa a **Amazon MSK** con dos brokers y replicación 2, que es lo que convierte el `acks=all` del productor en una garantía real. JMS pasa a **Amazon MQ** en activo/standby, porque la cola es la que garantiza que un retiro llegue al historial y una cola en una sola zona es un punto único de falla sobre el dato más sensible del sistema.

Los secretos van a **Secrets Manager** y se inyectan como variables de entorno; el código no cambia, porque ya los lee del entorno con un valor por defecto para la ejecución local.

Los tres jobs batch no son servicios: se ejecutan y terminan, así que van como tareas programadas de **EventBridge**, cada una con su propia frecuencia. El código de salida distinto de cero del proceso batch alimenta una alarma de CloudWatch, que es lo que hace que un batch fallido se sepa el mismo día.

El despliegue que sí se ejecutó. La arquitectura administrada que describen los párrafos anteriores —Fargate, MSK, Amazon MQ, RDS— está escrita con los comandos completos pero no se levantó: mantenerla cuesta del orden de 600 USD al mes, un orden de magnitud sobre la instancia única y tres sobre los veinte centavos que costó esta demostración.

Lo que sí se ejecutó, y es lo que `evidencia/nube/` registra, es el **sistema completo sobre una instancia EC2** —una `t3.large` en `us-east-1a`, identificada como `i-0edce5f77c07f3f19` en los metadatos que abren el primer registro—. Las once imágenes se construyeron dentro de la instancia desde el código fuente, y los trece contenedores quedaron arriba: doce residentes, **incluidos Artemis y Kafka, es decir los dos brokers de mensajería corriendo en la nube y no en el equipo de desarrollo**, más el de un solo uso que crea los tópicos y termina.

Sobre esa instancia se repitió el ejercicio completo: un retiro que bajó el saldo en `cuentas-service` y apareció en el historial de `pagos-service` por la cola JMS, tres operaciones y una alerta propagadas por Kafka entre dos titulares, el ciclo completo del circuit breaker, y treinta peticiones repartidas quince y quince entre dos réplicas de `cuentas-service` registradas en Eureka. Los pasos para reproducirlo están en la sección 11 de `despliegue.md`.

Dos mediciones de ese despliegue que no se ven en el entorno local y valen por sí solas. La primera: el gateway tardó **cinco segundos** en poder enrutar hacia `pagos-service` después de que el contenedor reportara `healthy`, y la cadena interna `pagos-service` → `cuentas-service` otro segundo más. Estar sano y estar en el registro de servicios no son lo mismo, y un sistema distribuido tiene una ventana de convergencia que hay que esperar en vez de suponer. La segunda: la consola de Eureka servida desde la instancia informa `num-of-cpus: 2`, las dos vCPU de la `t3.large`; la misma consola en el equipo de desarrollo informa 16. Es el tipo de detalle que distingue una captura de otra sin depender de lo que diga el pie de foto.

Una instancia única no demuestra tolerancia a la caída de una zona de disponibilidad: eso es precisamente lo que aporta la arquitectura administrada, y es la razón de describirla aunque no se haya levantado. La sección 0 de `despliegue.md` separa las dos mitades antes que cualquier otra cosa.

11. Conclusión

El sistema entregado cumple lo que el caso pedía: los tres procesos batch migrados a Spring Batch con escalado y tolerancia a fallos, el patrón BFF para los tres canales con autenticación y autorización propias de cada uno, y tres microservicios seguros y resilientes con Spring Cloud, Resilience4j, Kafka y JMS, desplegados en contenedores y escalables horizontalmente.

Lo que no cumple está dicho con la misma claridad en la sección 9, y la razón de escribirlo así es la que da el propio proyecto: durante el desarrollo, la falla más grave —la infraestructura sin autenticación— no apareció probando lo que estaba construido, sino preguntándose qué faltaba. Un informe que sólo enumera logros no deja ese hallazgo por escrito para quien venga después.